

Rétropropagation dans une Colonne Corticale : Une Synergie Performante mais Non Biologique sur MNIST

Architecture Corticale Bio-Inspirée : De la Mini-Colonne au Réseau Inter-Columnaire

La conception d'un modèle computationnel inspiré de la structure corticale humaine constitue une démarche visant à imiter la morphologie et l'organisation fonctionnelle du néocortex, organe principal de l'intelligence chez les mammifères [22](#). L'architecture proposée intègre plusieurs niveaux de structure hiérarchique, commençant par l'unité élémentaire, la mini-colonne, pour aboutir à un réseau de colonnes communicantes. Cette approche vise à créer une machine capable d'apprendre et de traiter des informations de manière distribuée et spécialisée, en s'inspirant des principes d'efficacité et de robustesse mis en œuvre par le cerveau [93](#) [98](#). La compréhension de cette architecture est fondamentale, car elle définit la manière dont les données sont reçues, transformées et combinées pour produire une décision finale.

Le concept de la mini-colonne est central à cette vision [154](#). Il s'agit d'un bloc fonctionnel élémentaire, répété de manière quasi identique à travers tout le cortex, qui forme la base de sa modularité [110](#). Bien que la définition exacte varie, une mini-colonne est généralement comprise comme un ensemble vertical de neurones (excitatoires et inhibiteurs) qui traverse les différentes couches corticales [88](#). Dans le modèle envisagé, ces mini-colonnes sont organisées verticalement pour former les six couches corticales distinctes, L1 à L6, chacune possédant ses propres caractéristiques morphologiques et fonctionnelles [181](#). L'hypothèse sous-jacente est que chaque mini-colonne traite une portion de l'information sensorielle, et que la répétition massive de ces unités permet une représentation robuste et redondante des stimuli [52](#). L'existence de nombreuses mini-colonnes dans le cortex est soutenue par de nombreuses études neuro-anatomiques [154](#).

L'organisation en couches est une autre caractéristique essentielle de la structure corticale. Les six couches (I à VI) ne sont pas toutes équivalentes ; elles présentent des différences significatives en termes de types de neurones, de densité dendritique et de

schémas de connexion [179](#). Par exemple, les projections ascendantes, qui portent l'information brute des senseurs (ou de la thalamus), se terminent principalement dans la couche 4 (L4), qui agit donc comme une entrée primaire pour la colonne [57](#). Ensuite, l'information circule vers les couches supérieures, L2/3, qui sont connues pour leur rôle dans la fusion d'informations top-down (issues des aires corticales supérieures) et bottom-up (descendantes). Les couches profondes, L5 et L6, sont quant à elles majoritairement responsables de l'envoi d'informations sortantes vers d'autres régions corticales et subcorticales [112138](#). Des connexions trans-laminaires complexes régulent ce flux d'information ; par exemple, une inhibition trans-laminaire provenant de L5 peut affiner la sélectivité des caractéristiques dans les couches superficielles [148](#). Un modèle réaliste doit donc intégrer ces connexions spécifiques plutôt que de simplement empiler des couches entièrement connectées. Les connexions entre les couches incluent des projections de L4 à L2/3, de L2/3 à L5, et de L5 à L6, formant un réseau de micro-circuits inter-laminaires [159](#). Ces schémas de connexion ont été reproduits dans des modèles de grande échelle comme celui de Potjans and Diesmann, qui utilise quatre couches (L2/3, L4, L5, L6) pour simuler une petite région du cortex [27](#).

Au-delà de la structure interne d'une seule colonne, le cortex opère comme un réseau de modules connectés. La "communication inter-colonnes" est donc un élément crucial de l'architecture. Cette connectivité n'est pas aléatoire ; elle obéit à des règles générales. Au sein d'une même aire corticale, des connexions horizontales distribuent les signaux principalement au sein des couches 2/3 et 5A [138](#). Entre différentes aires corticales, on observe une architecture à double sens contraire, où les connexions ascendantes et descendantes suivent des parcours distincts et ont des propriétés fonctionnelles différentes [9](#). De plus, il existe une tendance pour que les neurones ayant des propriétés de réponse similaires soient préférentiellement connectés, tant au sein qu'entre les colonnes [160](#). Modéliser cette connectivité, même de manière simplifiée, est important. Des approches comme les modèles mesoscopiques, qui représentent des populations de neurones plutôt que des neurones individuels, offrent un compromis judicieux entre la fidélité biologique et la viabilité computationnelle, permettant des gains de vitesse de simulation considérables, jusqu'à un facteur 120 par rapport aux simulations microscopiques détaillées [27](#). Le choix de l'échelle de modélisation (micro vs. meso) sera donc un arbitrage technique majeur pour ce projet.

Le tableau ci-dessous résume les rôles fonctionnels et les schémas de connexion typiques des différentes couches corticales, synthétisant des informations issues de la littérature.

Couche	Rôle Fonctionnel Principal	Connexions Intracorticales Principales
L1	Reçoit des signaux top-down (feedback) et neuromodulateurs ; organisation des dendrites apicales.	Recommandé pour le feedback depuis L2/3 et L5A 138 .
L2/3	Fusion d'informations bottom-up et top-down ; traitement associatif ; projection vers d'autres aires corticales.	Projection descendante vers L5 172 .
L4	Entrée primaire des signaux bottom-up (via le thalamus) ; détection de caractéristiques de base.	Projection ascendante vers L2/3 et L5 159 .
L5	Intégration d'informations pour la planification motrice ; sortie vers des structures subcorticales.	Projection retour vers L2/3 et L4 138 .
L6	Régulation du gain cortical ; modulation de l'entrée thalamique ; sortie vers le thalamus.	Projection retour vers L4 et L2/3 138 .

Cette architecture multi-niveaux, allant de la mini-colonne à l'aire corticale, crée un système de traitement d'information distribué et hiérarchique. L'information visuelle, par exemple, serait initialement captée par la couche L4, puis transformée et enrichie par les interactions trans-laminaires et inter-columnnaires à travers les couches supérieures, avant que des représentations abstraites ne soient envoyées vers d'autres régions du cerveau via les couches profondes. La mise en œuvre de cette complexité dans un modèle computationnel représente un défi majeur, mais offre également la promesse d'obtenir des systèmes d'apprentissage plus robustes et interprétables. La structure même du modèle, avec ses couches et ses colonnes spécialisées, pourrait permettre une analyse fine des représentations apprises, en contrastant les activations des différentes unités pour comprendre comment un chiffre comme '7' est distingué d'un '1' au fil du traitement hiérarchique [3](#).

Le Paradoxe de l'Apprentissage Supervisé : Intégration de la Rétropropagation dans une Architecture Corticale

Le choix de l'algorithme d'apprentissage pour le modèle cortical proposé est à la fois pragmatique et conceptuellement paradoxal. Pragmatiquement, la rétropropagation (BP) est l'algorithme qui a permis la percée des réseaux de neurones profonds, assurant une convergence rapide et des performances exceptionnelles sur des tâches de reconnaissance de formes comme celle posée par le jeu de données MNIST [100139](#). Conceptuellement, ce choix heurte une des convictions centrales de la neuroscience computationnelle : la rétropropagation est largement considérée comme peu plausible du point de vue neurobiologique [18 176](#). L'intégration de cet algorithme "non-biologique" au sein d'une

architecture hyper-détaillée et biologiquement inspirée constitue le cœur de la tension à évaluer dans cette recherche.

Les principales objections à la plausibilité biologique de la rétropropagation résident dans trois problèmes fondamentaux. Premièrement, le problème de l'attribution du crédit global. La rétropropagation nécessite le calcul d'un signal d'erreur global, qui est ensuite propagé en arrière à travers le réseau pour mettre à jour chaque poids synaptique [176](#). Ce signal est la dérivée de la fonction de perte par rapport à la sortie, multipliée par les dérivées partielles des activations intermédiaires. Le cerveau n'a manifestement pas accès à un tel signal global et instantané ; il n'existe aucun "enseignant" externe fournissant une erreur dérivée pour chaque neurone [55](#). Deuxièmement, le problème de la symétrie des poids. La règle de la rétropropagation stipule que pour que le gradient soit correctement propagé, les poids des connexions en avant (w_{ij}) doivent être identiques aux poids des connexions de retour (w_{ji}). Or, il n'existe aucune preuve expérimentale de ce type de symétrie stricte dans le cortex [147](#). Les connexions ascendantes et descendantes entre aires corticales sont anatomiquement distinctes. Troisièmement, le problème de la synchronisation temporelle. La rétropropagation repose sur une séquence rigide d'événements : calcul de la sortie, calcul de l'erreur, puis propagation de l'erreur. Cela implique une synchronisation précise dans le temps, ce qui est incompatible avec le mode d'apprentissage continu et en ligne du cerveau, où les événements sont spikants et asynchrones [6](#).

Malgré ces inconvénients, la rétropropagation reste un outil extrêmement efficace. Sa performance sur des tâches standard comme MNIST est indéniable. Des études montrent que des réseaux profonds, y compris des réseaux de neurones spikants (SNNs) qui tentent de plus près l'activité neuronale réelle, peuvent atteindre des taux de précision supérieurs à 99% sur MNIST en utilisant des variantes de la rétropropagation [15](#) [100](#). Le choix de la rétropropagation dans ce projet de recherche semble donc être un compromis stratégique : sacrifier la plausibilité biologique de l'algorithme d'apprentissage pour maximiser les performances et valider la capacité d'apprentissage fondamentale du modèle cortical lui-même. L'objectif n'est pas de construire un modèle parfaitement biologique, mais de tester si une structure corticale complexe peut tirer parti d'un algorithme d'apprentissage puissant.

Face aux limitations de la rétropropagation, de nombreuses recherches tentent de trouver des solutions pour la rendre plus biologiquement plausible. Une approche notable est l'alignement de retour [147](#). Plutôt que d'utiliser des poids de retour identiques à ceux de l'avant, cette méthode propose d'utiliser des matrices de poids de retour fixes et aléatoires. L'idée est que ces poids de retour mal définis peuvent encore véhiculer une

information utile sur la direction de l'erreur, suffisante pour maintenir la stabilité du réseau et permettre l'apprentissage. Cette approche conserve la nature locale de l'ajustement des poids (chaque synapse ne voit que son propre signal local) tout en se débarrassant de la contrainte de symétrie. Une autre série de travaux explore des méthodes sans gradient ou des algorithmes locaux qui cherchent à contourner le problème de l'attribution du crédit en utilisant des mécanismes plus distribués. Par exemple, l'algorithme Forward-Forward (FF) apprend en comparant les activations sur deux types de données différentes (données positives et négatives) sans jamais calculer d'erreur explicite [30](#) [75](#). D'autres méthodes explorent la plasticité synaptique Hebbienne combinée à des formes de plasticité prédictive pour apprendre des représentations invariantes [16](#) [134](#). Pour les SNNs, des ajustements spatio-temporels ont été proposés pour mieux correspondre à la transmission d'informations par des pics d'activité, en régulant le calcul du gradient en fonction de la dynamique membranaire du neurone [15](#) [46](#).

Dans le contexte de ce projet, l'utilisation de la rétropropagation classique peut être justifiée comme une première étape pour établir un benchmark de performance. Cependant, une analyse complète de la capacité d'apprentissage devrait aller plus loin. Elle pourrait explorer la robustesse de l'approche hybride en introduisant progressivement des contraintes biologiques. Par exemple, on pourrait modifier le processus de rétropropagation pour utiliser des poids de retour non symétriques ou mal définis et observer l'impact sur la convergence et la précision. Une telle expérience permettrait de quantifier jusqu'où la puissance de la rétropropagation peut compenser les imperfections d'un canal de rétroaction moins idéal, et d'éclairer les conditions minimales pour que la structure corticale puisse bénéficier de cet algorithme d'apprentissage. En somme, le choix de la rétropropagation n'est pas seulement une question technique, mais aussi une stratégie de recherche qui positionne le modèle cortical non pas comme une imitation parfaite du cerveau, mais comme un système hybride dont l'étude peut révéler des synergies inattendues entre la structure et l'algorithme.

Mécanisme de Vote Cortical : Stratégie d'Ensemble pour la Décision Collective

Le mécanisme de vote entre colonnes corticales est présenté comme un élément final pour synthétiser les décisions individuelles de chaque colonne et arriver à un consensus. Cette approche s'inscrit dans le paradigme de l'apprentissage par ensembles, une stratégie éprouvée en apprentissage automatique pour améliorer la robustesse et la précision des

modèles prédictifs [91](#). Plutôt que de compter sur la performance d'un seul modèle, souvent appelé "expert", un vote collectif combine les prédictions de plusieurs modèles pour prendre une décision finale. Dans le cadre du modèle cortical, chaque colonne peut être vue comme un expert spécialisé, ayant appris des représentations uniques des données d'entrée, et le vote agit comme un mécanisme de fusion pour capitaliser sur cette diversité. Cette idée trouve un écho dans le fonctionnement du cerveau lui-même, où une décision complexe résulte souvent de l'interaction et de la compétition entre différents groupes de neurones ou régions cérébrales [19](#).

Plusieurs études confirment empiriquement l'efficacité du vote pour améliorer les performances. Par exemple, dans le contexte des réseaux de neurones spikants (SNNs), une approche de vote a permis d'améliorer le taux de précision sur le jeu de données MNIST [15](#). De manière plus spectaculaire, une étude sur un modèle de colonne corticale basé sur des équations différentielles ordinaires (nmODE) a montré que l'implémentation d'un mécanisme de vote parmi cinq modèles indépendamment entraînés a permis d'augmenter le taux de précision sur l'ensemble de test de plus de 99,52 % à 99,71 % [85](#). De même, sur une autre tâche de classification médicale, un modèle d'ensemble combinant un SVM, une régression logistique, un naïve Bayes et un K plus proches voisins a vu son taux de précision passer de 93 % (pour le meilleur classificateur individuel) à 96,4 % grâce à une stratégie de vote majoritaire [91](#). Ces exemples démontrent que le simple fait de combiner les résultats de plusieurs modèles, même s'ils ne sont pas massivement différents, peut conduire à une amélioration statistiquement significative.

L'implémentation d'un tel mécanisme de vote peut prendre plusieurs formes. La plus simple est le vote majoritaire dur, où chaque colonne (ou modèle) émet une prédiction de classe, et la classe qui reçoit le plus grand nombre de votes est choisie comme décision finale [91](#). Une variante est le vote majoritaire doux, où chaque colonne fournit une distribution de probabilités sur toutes les classes possibles. Ces distributions sont ensuite moyennées, et la classe avec la probabilité moyenne la plus élevée est sélectionnée. Cette dernière approche peut être plus performante car elle pondère les certitudes de chaque modèle. Une autre perspective, plus dynamique, est celle de la compétition gagnante s'empare (sWTA), où les colonnes ne votent pas simultanément, mais participent à une compétition où un seul gagnant est désigné [37](#). Ce mécanisme peut être simulé par des circuits d'inhibition latérale, où les neurones activés par une entrée donnée inhibent les neurones des autres colonnes, créant une compétition qui favorise une réponse claire et discriminante [36](#) [90](#). Un tel circuit est particulièrement pertinent dans un contexte spiking, où seul un petit nombre de neurones ou de colonnes peuvent être "actifs" à un moment donné.

Au-delà de sa fonction purement statistique d'amélioration de la précision, le vote peut servir d'outil analytique pour comprendre la dynamique interne du réseau cortical. Si toutes les colonnes votent approximativement pour la même classe, cela indique un haut degré de consensus et une forte confiance dans la décision. À l'inverse, un vote serré ou hétérogène peut signaler une ambiguïté dans l'entrée ou un manque de convergence dans l'apprentissage. En analysant les cartes de vote, on pourrait visualiser quels types de motifs (par exemple, des variations spécifiques d'un chiffre MNIST) sont bien capturés par la majorité des colonnes, et quels motifs provoquent des divergences. Cela pourrait révéler les faiblesses du modèle et guider son amélioration.

Le tableau suivant compare différentes stratégies de vote et leur pertinence potentielle pour le modèle cortical.

Type de Vote	Description	Avantages	Inconvénients
Majoritaire Dur	La classe majoritaire parmi les votes des colonnes est sélectionnée.	Simple à implémenter, interprétable.	Ne prend pas en compte la confiance ou la certitude de chaque colonne.
Majoritaire Doux	Les probabilités de classe de chaque colonne sont moyennées avant de choisir la classe.	Poids les prédictions les plus certaines, souvent plus précis que le vote dur.	Nécessite que chaque colonne fournisse une estimation de probabilité valide.
Compétition Gagnant S'Empare Stochastique (sWTA)	Seule une ou quelques colonnes "gagnent" la compétition pour envoyer la réponse finale.	Simule une compétition neuronale, peut renforcer la discrimination.	Peut perdre de l'information contenue dans les votes minoritaires.
Vote Ponderé	Chaque colonne a un poids différent dans le vote, basé sur sa performance passée ou sa diversité.	Permet de donner plus de crédit aux colonnes les plus fiables ou les plus originales.	Nécessite un mécanisme pour calculer et ajuster les poids de vote.

L'intégration d'un mécanisme de vote dans le modèle cortical est donc une étape cruciale. Elle transforme le système d'une collection de colonnes autonomes en un véritable système de décision collectif. Cette approche non seulement vise à améliorer la performance quantitative sur des tâches comme MNIST, mais elle ouvre également des perspectives pour une meilleure interprétation des processus computationnels internes. En examinant les dynamiques de vote, on peut espérer obtenir un aperçu de la manière dont une intelligence distribuée pourrait émerger d'un réseau de processeurs spécialisés et interactifs, un objectif central de l'IA inspirée du cerveau.

Évaluation de la Performance sur le Jeu de Données MNIST : Convergence et Précision

L'évaluation de la capacité d'apprentissage du modèle cortical se concentrera sur son comportement lors de l'entraînement sur le jeu de données MNIST. Ce jeu de données, constitué d'images de chiffres manuscrits de 28x28 pixels, est un standard de facto pour les tâches de reconnaissance de formes et offre un cadre de test contrôlé et bien documenté [61](#). Les métriques clés pour cette évaluation seront la vitesse de convergence (le nombre d'époques nécessaires pour atteindre une performance satisfaisante) et la précision finale sur un ensemble de validation ou de test. L'analyse de ces métriques permettra de répondre directement à la question centrale : le modèle est-il capable d'apprendre efficacement ?

La rétropropagation étant l'algorithme choisi, on peut s'attendre à une convergence relativement rapide, à condition que l'architecture et la mise en œuvre soient correctes. Des études sur des modèles bio-inspirés et avancés montrent que des performances très élevées peuvent être atteintes en peu de temps. Par exemple, un modèle utilisant une couche de « BioLogicalNeuron » a atteint une précision de 96 % sur MNIST en seulement une époque, ce qui représente une réduction de 75 % du temps d'entraînement nécessaire pour atteindre ce seuil par rapport aux approches standards [21](#). D'autres travaux sur des SNNs entraînés avec des variantes de la rétropropagation ont atteint des taux de précision supérieurs à 99,5 % sur MNIST après environ 300 époques [15](#). Ces résultats suggèrent que, si le modèle cortical est capable de converger, il devrait pouvoir atteindre des niveaux de performance comparables à ceux des meilleurs modèles d'apprentissage automatique profond, qui eux-mêmes dépassent souvent 99,5 % de précision [100](#).

Un aspect unique de l'architecture cortical est sa potentialité pour l'interprétabilité. Contrairement aux « boîtes noires » où il est difficile d'inspecter ce qui se passe à l'intérieur, la structure hiérarchique du modèle offre une fenêtre potentielle sur les représentations apprises. Une analyse des cartes d'activation de chaque couche peut révéler si le modèle respecte une hiérarchie de traitement semblable à celle observée dans le cortex visuel primate [20](#). On s'attendrait à ce que la couche d'entrée (simulant probablement la L4) détecte des motifs de base, tels que des bords et des coins [57](#). Les couches intermédiaires (L2/3, L5) devraient alors combiner ces motifs pour former des représentations plus complexes et partiellement invariantes, tandis que les couches de sortie (L5/L6) apprendraient des abstractions finales correspondant aux classes de chiffres [3](#). Des recherches antérieures ont déjà montré qu'il était possible de faire correspondre les activités de neurones V4 dans le cortex visuel avec les activations de

couches spécifiques de réseaux de neurones convolutifs, avec une précision de prédiction record 83. Appliquer une telle analyse au modèle cortical permettrait de vérifier si ses couches apprennent effectivement des représentations hiérarchiques et informatives.

Le tableau suivant présente des résultats de référence sur MNIST issus de la littérature, servant de benchmarks pour évaluer les performances du modèle cortical.

Modèle / Méthode	Précision (%)	Spécificités
CNN Classique (Ex: LeNet-5)	> 99	Baseline historique et performant 61.
Réseau de Neurones Spikants (BP)	99.67 15	Utilise des ajustements spatiaux et temporels.
Réseau de Neurones Spikants (STBP)	99.42 15	Rétropropagation Temporelle Synchrone.
BioLogicalNeuron Layer	99.43 21	A atteint >96 % en 1 époque.
nmODE (avec vote)	99.71 85	Basé sur des équations différentielles ordinaires.
Deep Linear Network (local-SSL)	~98.5 (simulation) 164	Simulation sur un réseau linéaire de 6 couches.

La capacité de généralisation est un corollaire essentiel de la capacité d'apprentissage. Un modèle qui se contente de mémoriser les images d'entraînement sans pouvoir reconnaître de nouveaux exemples est considéré comme ayant échoué. Pour évaluer la généralisation, il est impératif de tester le modèle non seulement sur l'ensemble de test standard de MNIST, mais aussi sur des versions altérées du jeu de données. Des tests avec ajout de bruit, de rotation, de déformation affine, ou même de superposition de chiffres pourraient fournir un indicateur fort de la robustesse de l'apprentissage. Une bonne généralisation suggère que le modèle a appris des caractéristiques intrinsèques et invariantes des chiffres, plutôt que des signatures parasites liées à un style d'écriture particulier. Des techniques comme la distillation de connaissance, qui consiste à entraîner un nouveau modèle pour qu'il reproduise les sorties d'un modèle existant, peuvent aider à améliorer la généralisation en découplant le modèle enseignant des bruits présents dans les données d'entraînement 40. De même, encourager une faible corrélation entre les filtres ou les neurones peut renforcer la capacité du modèle à s'adapter à de nouvelles situations 67. L'évaluation de la capacité d'apprentissage sur MNIST, bien que limitée à un domaine spécifique, est un premier pas indispensable pour valider les principes computationnels sous-jacents avant de les appliquer à des tâches plus complexes et multimodales.

Analyse Comparée et Limites de l'Approche Hybride

L'évaluation de la capacité d'apprentissage d'un modèle cortical bio-inspiré utilisant la rétropropagation sur MNIST conduit à une analyse comparative et à une discussion sur les limites inhérentes à cette approche hybride. Le succès du modèle ne doit pas seulement être jugé par sa capacité à atteindre une haute précision, mais aussi par la compréhension qu'il apporte sur la synergie (ou la dissonance) entre une structure computationnelle fortement ancrée dans la biologie et un algorithme d'apprentissage qui l'est beaucoup moins. Cette section synthétise les forces et les faiblesses de l'approche et ouvre la voie à des perspectives de recherche futures.

Le principal avantage de cette architecture est sa potentialité d'interprétabilité. En raison de sa structure hiérarchique et modulaire, le modèle cortical offre une fenêtre sur le processus de traitement de l'information qui est absente dans les réseaux profonds traditionnels. En analysant les activations des différentes couches, il est possible de vérifier si le modèle apprend une hiérarchie de représentations, passant de descripteurs simples à des concepts abstraits, un principe fondamental du traitement visuel [3](#) [20](#). Cette capacité à "regarder à l'intérieur" du modèle est un atout considérable pour la neuroscience computationnelle, car elle permet de tester des hypothèses sur le fonctionnement du cortex. De plus, la structure modulaire, avec ses colonnes et son mécanisme de vote, est intrinsèquement parallèle et distribuée, ce qui peut offrir des avantages en termes de robustesse face aux défaillances de certains de ses composants, une propriété importante pour les systèmes intelligents.

Cependant, le principal compromis de cette approche réside dans l'utilisation de la rétropropagation. En sacrifiant la plausibilité biologique de l'algorithme d'apprentissage, le modèle échoue à adresser l'un des grands mystères de l'intelligence : comment le cerveau apprend-il de manière autonome et continue sans un enseignant externe fournissant un signal d'erreur global. La rétropropagation, bien que performante, reste un artefact computationnel qui ne correspond à aucune observation neurophysiologique directe [176](#). L'intégration de cette méthode dans un modèle cortical crée une dualité : une partie de l'architecture est biologiquement plausible (la structure), tandis que le moteur d'apprentissage qui la fait fonctionner ne l'est pas. Cette dichotomie soulève la question de savoir si la structure même du cortex est optimisée pour un algorithme comme la rétropropagation, ou si elle est conçue pour fonctionner avec des règles locales et distribuées bien différentes.

Les limites de l'approche sont multiples. Premièrement, la fidélité biologique est incomplète. Même si l'on modélise les mini-colonnes et les couches, de nombreux aspects

restent simplifiés : la diversité des types de neurones inhibiteurs et excitateurs, les dynamiques spatio-temporelles réalistes des pics, la plasticité synaptique locale, etc. ²⁷ ⁸⁸. Deuxièmement, l'efficacité computationnelle est une préoccupation majeure. Des architectures corticales détaillées, si elles étaient simulées à l'échelle du cerveau, seraient extrêmement coûteuses en calcul. Des techniques de modélisation mesoscopique peuvent aider à atténuer ce problème, mais une perte de détail est inévitable ²⁷. Troisièmement, l'évaluation sur MNIST, bien que nécessaire, est insuffisante pour évaluer pleinement les capacités d'un système bio-inspiré. Le jeu de données ne teste ni la capacité à apprendre en continu sans oublier (continual learning), ni la gestion de l'incertitude, ni la généralisation à de nouvelles modalités sensorielles. Le passage à des tâches plus complexes comme CIFAR-10 ou ImageNet, ou à des scénarios d'apprentissage en ligne, révélerait rapidement les limites de l'approche hybride ⁴¹ ⁹⁴.

Malgré ces limites, ce projet de recherche ouvre des avenues de recherche passionnantes. Une direction future consisterait à remplacer progressivement la rétropropagation par des alternatives plus biologiques. Tester le modèle avec des algorithmes comme l'alignement de retour, l'algorithme forward-forward ou d'autres méthodes locales permettrait de quantifier la contribution spécifique de la rétropropagation à la performance observée ³⁰ ¹⁴⁷. Une autre piste serait d'explorer comment la structure corticale elle-même peut aider à surmonter les défis de ces algorithmes alternatifs. Par exemple, la hiérarchie de couches pourrait être utilisée pour organiser l'apprentissage local de manière plus efficace. Enfin, l'étude du mécanisme de vote pourrait être approfondie pour modéliser des dynamiques de compétition plus réalistes, comme celles impliquant l'inhibition latérale, et voir comment ces dynamiques influencent à la fois la précision et la robustesse du système ⁹⁰.

En conclusion, l'évaluation de la capacité d'apprentissage d'un modèle cortical bio-inspiré avec rétropropagation sur MNIST est une entreprise à double tranchant. D'un côté, elle permet de valider que des structures computationnelles biologiquement plausibles peuvent fonctionner de manière très efficace lorsqu'elles sont alimentées par un algorithme d'apprentissage puissant, atteignant des niveaux de performance de pointe. De l'autre côté, elle met en lumière le fossé persistant entre notre compréhension de la structure du cerveau et notre compréhension de son mode d'apprentissage. Le succès de ce projet ne sera pas seulement mesuré par un pourcentage de précision, mais aussi par la clarification de ce fossé : quelle est la contribution respective de la structure et de l'algorithme ? Et surtout, comment concevoir des systèmes qui combinent la robustesse et l'efficacité de la structure corticale avec la flexibilité et la puissance d'un algorithme d'apprentissage véritablement biologique ?

Référence

1. A sparse quantized hopfield network for online-continual memory <https://pmc.ncbi.nlm.nih.gov/articles/PMC11065890/>
2. [PDF] Semantic and episodic memories in a predictive coding model ... - HAL <https://hal.science/hal-05202850v1/file/main.pdf>
3. The Proceedings of the Fourth IEEE International Conference on ... https://icrc.ieee.org/files/2019/11/icrc_2019-ebook.pdf
4. 人工智能2026_5_7 - arXiv每日学术速递 <https://www.arxivdaily.com/thread/79593>
5. Appl. Sci., Volume 13, Issue 3 (February-1 2023) – 798 articles - MDPI <https://www.mdpi.com/2076-3417/13/3>
6. Backpropagation through space, time and the brain - Nature <https://www.nature.com/articles/s41467-025-66666-z>
7. Constructing biologically constrained RNNs via Dale's ... - Science <https://www.science.org/doi/10.1126/sciadv.adw4970>
8. Hierarchy or Heterarchy? A Theory of Long-Range Connections for ... <https://arxiv.org/html/2507.05888v1>
9. Cortical hierarchy, dual counterstream architecture and the ... <https://www.sciencedirect.com/science/article/pii/S1053811920309642>
10. Cellular and Network Mechanisms for Temporal Signal Propagation ... <https://www.frontiersin.org/journals/computational-neuroscience/articles/10.3389/fncom.2019.00057/full>
11. Simulations of cortical networks using spatially extended ... <https://physoc.onlinelibrary.wiley.com/doi/full/10.1113/JP284030>
12. [PDF] On Exact Computation with an Infinitely Wide Neural Net - arXiv <https://arxiv.org/pdf/1904.11955>
13. A data-based large-scale model for primary visual cortex enables ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC9629744/>
14. Algorithms for Fast Spiking Neural Network Simulation on FPGAs <https://ieeexplore.ieee.org/iel8/6287639/10380310/10716361.pdf>
15. Backpropagation with biologically plausible spatiotemporal ... - PMC <https://pmc.ncbi.nlm.nih.gov/articles/PMC9214320/>

16. The combination of Hebbian and predictive plasticity learns invariant ... <https://www.nature.com/articles/s41593-023-01460-y>
17. [PDF] BackEISNN: A Deep Spiking Neural Network with Adaptive Self ... <https://arxiv.org/pdf/2105.13004>
18. When brain-inspired AI meets AGI - ScienceDirect.com <https://www.sciencedirect.com/science/article/pii/S295016282300005X>
19. Cortical mechanisms of action selection: the affordance competition ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC2440773/>
20. Comparison of deep neural networks to spatio-temporal cortical ... <https://www.nature.com/articles/srep27755>
21. Biologically inspired neural network layer with homeostatic ... - PMC <https://pmc.ncbi.nlm.nih.gov/articles/PMC12484884/>
22. Bridging Brains and Machines: A Unified Frontier in Neuroscience ... <https://arxiv.org/html/2507.10722v1>
23. Biologically motivated learning method for deep neural networks ... <https://www.sciencedirect.com/science/article/pii/S0893608021003403>
24. Concept transfer of synaptic diversity from biological to artificial ... <https://www.nature.com/articles/s41467-025-60078-9>
25. Biologically Inspired Spatial–Temporal Perceiving Strategies for ... <https://www.mdpi.com/2313-7673/10/1/48>
26. Sparse connectivity enables efficient information processing in ... <https://www.frontiersin.org/journals/neural-circuits/articles/10.3389/fncir.2025.1528309/full>
27. Towards a theory of cortical columns: From spiking neurons ... - PMC <https://pmc.ncbi.nlm.nih.gov/articles/PMC5415267/>
28. The backpropagation algorithm implemented on spiking ... - Nature <https://www.nature.com/articles/s41467-024-53827-9>
29. CONSTRUCTING BIOLOGICALLY CONSTRAINED RNNS VIA ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC11760306/>
30. Backpropagation-free Spiking Neural Networks with the Forward ... <https://arxiv.org/html/2502.20411v2>
31. Contextual Integration in Cortical and Convolutional Neural Networks <https://www.frontiersin.org/journals/computational-neuroscience/articles/10.3389/fncom.2020.00031/full>
32. Artificial Neural Networks for Neuroscientists: A Primer - ScienceDirect <https://www.sciencedirect.com/science/article/pii/S0896627320307054>

33. An unsupervised STDP-based spiking neural network inspired by ... <https://www.sciencedirect.com/science/article/pii/S0893608023003301>
34. Neurobiological mechanisms for language, symbols and concepts <https://pmc.ncbi.nlm.nih.gov/articles/PMC10518464/>
35. Enhanced representation learning with temporal coding in sparsely ... <https://www.frontiersin.org/journals/computational-neuroscience/articles/10.3389/fncom.2023.1250908/full>
36. Timing – Dependent Spiking Neural Network: Board – Level Hardware ... <https://advanced.onlinelibrary.wiley.com/doi/10.1002/adma.202517613>
37. Unsupervised Learning in an Ensemble of Spiking Neural Networks ... <https://journals.plos.org/ploscompbiol/article?id=10.1371/journal.pcbi.1005137>
38. BackEISNN: A deep spiking neural network with adaptive self ... <https://www.sciencedirect.com/science/article/pii/S0893608022002520>
39. [PDF] Testing Feedforward Neural Networks Training Programs - arXiv <https://arxiv.org/pdf/2204.00694>
40. Subspace distillation for continual learning - ScienceDirect.com <https://www.sciencedirect.com/science/article/pii/S0893608023004057>
41. How small is big enough? Open labeled datasets and the ... <https://academic.oup.com/icc/article/34/6/1322/8300900>
42. Machine Learning for Microcontroller-Class Hardware: A Review <https://pmc.ncbi.nlm.nih.gov/articles/PMC9683383/>
43. Neural Networks for Constitutive Modeling: From Universal Function ... <https://link.springer.com/article/10.1007/s11831-023-10009-y>
44. 人工智能2026_5_7 - arXiv每日学术速递 <http://www.arxivdaily.com/thread/79593>
45. [PDF] Gradient-Free Continual Learning in Spiking Neural Networks via ... <https://arxiv.org/pdf/2604.16496>
46. Article Backpropagation with biologically plausible spatiotemporal ... <https://www.sciencedirect.com/science/article/pii/S2666389922001192>
47. A Sparsity-Driven Backpropagation-Less Learning Framework ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC8355563/>
48. [PDF] An Unsupervised Spiking Neural Network Inspired By ... - arXiv <https://arxiv.org/pdf/2207.02727>
49. Biologically-informed excitatory and inhibitory ratio for robust spiking ... <https://www.nature.com/articles/s41598-025-03408-7>
50. A biologically inspired architecture with switching units can learn to ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC10843013/>

51. Variation and convergence in the morpho-functional properties of ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC11222651/>
52. (PDF) Why Does the Neocortex Have Columns, A Theory of ... https://www.researchgate.net/publication/345727435_Why_Does_the_Neocortex_Have_Columns_A_Theory_of_Learning_the_Structure_of_the_World
53. Brain Computations and Connectivity - Oxford Academic https://academic.oup.com/book/46855/book-pdf/53429884/9780198887928_web.pdf
54. Optimal degrees of synaptic connectivity - PMC - NIH <https://pmc.ncbi.nlm.nih.gov/articles/PMC5379477/>
55. [PDF] Neural mechanisms of predictive processing https://www.cns.nyu.edu/wanglab/publications/pdf/prediction_review_mejias_meng_wang2026.pdf
56. Synaptic plasticity facilitates oscillations in a V1 cortical column ... <https://www.frontiersin.org/journals/computational-neuroscience/articles/10.3389/fncom.2025.1568143/full>
57. [PDF] Predictive Coding: a Theoretical and Experimental Review - arXiv <https://arxiv.org/pdf/2107.12979>
58. Enhancing deep neural networks through complex-valued ... - PMC <https://pmc.ncbi.nlm.nih.gov/articles/PMC12340886/>
59. A sparse quantized hopfield network for online-continual memory <https://www.nature.com/articles/s41467-024-46976-4>
60. 2022 roadmap on neuromorphic computing and engineering <https://iopscience.iop.org/article/10.1088/2634-4386/ac4a83>
61. Categories - Echo Blog - GitHub Pages <https://houbb.github.io/categories/>
62. RAG Daily Papers - Latest RAG Research from arXiv <https://ragdaily.com/>
63. A Cautionary Tale in Deep Neuroimaging using Autoencoders - arXiv <https://arxiv.org/html/2509.03675v1>
64. [PDF] A Temporal Neural Network Architecture for Online Learning - arXiv <https://arxiv.org/pdf/2011.13844>
65. Agentic World Modeling: Foundations, Capabilities, Laws, and Beyond <https://arxiv.org/html/2604.22748v1>
66. [PDF] Modelling of consciousness and interpretation of quantum mechanics <https://arxiv.org/pdf/1807.07669>
67. [PDF] MMA Regularization: Decorrelating Weights of Neural Networks by ... <https://arxiv.org/pdf/2006.06527>
68. [PDF] arXiv:2110.09148v1 [eess.IV] 18 Oct 2021 <https://arxiv.org/pdf/2110.09148>

69. [PDF] Can phones, syllables, and words emerge as side-products of cross ... <https://arxiv.org/pdf/2109.14200>
70. (PDF) 34th Annual Computational Neuroscience Meeting: CNS*2025 https://www.researchgate.net/publication/399863380_34th_Annual_Computational_Neuroscience_Meeting_CNS2025
71. [PDF] Exploration of brain-inspired computing with self-organizing ... <https://theses.hal.science/tel-03186924/file/2020COAZ4085.pdf>
72. All Topics - cse, hkust <https://cse.hkust.edu.hk/~lzhang/topic/Nips/TopicsTable.html>
73. Appl. Sci., Volume 12, Issue 23 (December-1 2022) – 631 articles <https://www.mdpi.com/2076-3417/12/23>
74. Engineering Applications of Neural Networks - Springer Nature <https://link.springer.com/content/pdf/10.1007/978-3-031-34204-2.pdf>
75. [PDF] arXiv:2206.01820v2 [cs.NE] 5 Nov 2023 <https://arxiv.org/pdf/2206.01820>
76. Localist Topographic Expert Routing: A Barrel Cortex-Inspired... <https://openreview.net/forum?id=1Y8MXuJlIY>
77. (PDF) Biologically grounded neocortex computational primitives ... https://www.researchgate.net/publication/396292612_Biologically_grounded_neocortex_computational_primitives_implemented_on_neuromorphic_hardware_improve_vision_transformer_performance
78. (PDF) Predictive Coding: a Theoretical and Experimental Review https://www.researchgate.net/publication/353510198_Predictive_Coding_a_Theoretical_and_Experimental_Review
79. Photonics for Neuromorphic Computing: Fundamentals, Devices ... <https://advanced.onlinelibrary.wiley.com/doi/10.1002/adma.202312825>
80. The Experimentalist's Guide to Machine Learning for Small Molecule ... <https://pubs.acs.org/doi/10.1021/acsabm.3c00054>
81. [PDF] Benchmarking the Accuracy and Robustness of Feedback ... - arXiv <https://arxiv.org/pdf/2108.13446>
82. (PDF) Can Local Learning Match Self-Supervised Backpropagation? https://www.researchgate.net/publication/400237592_Can_Local_Learning_Match_Self-Supervised_Backpropagation
83. [PDF] Interpretable Machine Learning with Applications in Neuroscience ... https://escholarship.org/content/qt94r7n062/qt94r7n062_noSplash_04e05036b9391289bad328e02ccf835f.pdf
84. Toward Enhancing Privacy Preservation of a Federated Learning ... <https://dl.acm.org/doi/10.1145/3695998>

85. nmODE: neural memory ordinary differential equation <https://link.springer.com/article/10.1007/s10462-023-10496-2>
86. Advanced Intelligent Computing Technology and Applications <https://link.springer.com/content/pdf/10.1007/978-981-96-9946-9.pdf>
87. [PDF] NEURAL NETWORKS FOR SIGNAL PROCESSING ... - ResearchGate https://www.researchgate.net/profile/Marwan_Jabri/publication/3711576_Classification_and_compression_of_ICEGS_using_Gaussian_mixture_models/links/0a85e53b365d42efe4000000.pdf
88. A Comparative Perspective on Minicolumns and Inhibitory ... - PMC <https://pmc.ncbi.nlm.nih.gov/articles/PMC2820381/>
89. [PDF] Cortical plasticity, dynamic neural fields and self-organization <https://theses.hal.science/tel-00879910/PDF/thesis.pdf>
90. Neuronal Correlates of Local, Lateral, and Translaminar Inhibition ... https://www.researchgate.net/publication/210293173_Neuronal_Correlates_of_Local_Lateral_and_Translaminar_Inhibition_with_Reference_to_Cortical_Columns
91. Voting Ensemble Approach for Enhancing Alzheimer's Disease ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC9571155/>
92. [PDF] Bio-inspired Continuous Learning in Associative Memory Networks <https://theses.hal.science/tel-05536556/document>
93. Efficient Neural Networks for Tiny Machine Learning <https://dl.acm.org/doi/full/10.1145/3798276>
94. Hardware implementation of memristor-based artificial neural ... <https://www.nature.com/articles/s41467-024-45670-9>
95. Deep Learning: Basics and Convolutional Neural Networks (CNNs) <https://www.ncbi.nlm.nih.gov/books/NBK597497/>
96. Hybrid Quantum–Classical Neural Networks for Efficient MNIST ... <https://www.mdpi.com/2227-7390/12/23/3684>
97. Targeted deep learning classification and feature extraction for ... [https://www.cell.com/iscience/fulltext/S2589-0042\(23\)02083-7](https://www.cell.com/iscience/fulltext/S2589-0042(23)02083-7)
98. [PDF] Efficient Neural Networks for Tiny Machine Learning - HAL <https://hal.science/hal-04296440/document>
99. (PDF) Review of deep learning: concepts, CNN architectures ... https://www.researchgate.net/publication/350527503_Review_of_deep_learning_concepts_CNN_architectures_challenges_applications_future_directions
100. Learning in the machine: Random backpropagation and the deep ... <https://www.sciencedirect.com/science/article/pii/S0004370218300985>

101. Reliable uncertainty estimates in deep learning with efficient ... <https://www.nature.com/articles/s41467-026-70015-z>
102. Modeling memristor-based neural networks with Manhattan update https://www.researchgate.net/publication/403417874_Modeling_memristor-based_neural_networks_with_Manhattan_update_Trade-offs_in_learning_performance_and_energy_consumption
103. Low-memory stochastic backpropagation for convolutional layers <https://arxiv.org/html/2106.06998v3>
104. A New Weight Initialization Method for the Backpropagation of Deep ... <https://www.mdpi.com/2504-2289/9/7/181>
105. Multi-column Deep Neural Networks for Image Classification https://www.researchgate.net/publication/221663833_Multi-column_Deep_Neural_Networks_for_Image_Classification
106. [PDF] Modularity in Artificial Neural Networks - CORE <https://core.ac.uk/download/467106685.pdf>
107. Artificial Neural Networks – ICANN 2010 - Springer Nature <https://link.springer.com/content/pdf/10.1007/978-3-642-15825-4.pdf>
108. [PDF] 25th Annual Computational Neuroscience Meeting: CNS-2016 - HAL <https://hal.science/hal-03598912v1/file/main.pdf>
109. A role for cortical interneurons as adversarial discriminators - PMC <https://pmc.ncbi.nlm.nih.gov/articles/PMC10538760/>
110. The Generalist Brain Module: Module Repetition in Neural Networks ... https://www.researchgate.net/publication/393783636_The_Generalist_Brain_Module_Module_Repetition_in_Neural_Networks_in_Light_of_the_Minicolumn_Hypothesis
111. [PDF] Synaptic identity of neocortical circuits involving Martinotti cells in ... https://theses.hal.science/tel-03265141v1/file/DONATO_Cristina_2019.pdf
112. Three Types of Cortical Layer 5 Neurons That Differ in Brain-wide ... https://www.researchgate.net/publication/286048435_Three_Types_of_Cortical_Layer_5_Neurons_That_Differ_in_Brain-wide_Connectivity_and_Function
113. (PDF) Attention, please! A survey of neural attention models in deep ... https://www.researchgate.net/publication/358995968_Attention_please_A_survey_of_neural_attention_models_in_deep_learning
114. Artificial Neural Networks and Machine Learning – ICANN 2024 <https://link.springer.com/content/pdf/10.1007/978-3-031-72332-2.pdf>
115. Jian Li's Publications <https://people.iis.tsinghua.edu.cn/~jianli/paper-date.htm>

116. 机器学习2024_12_3 - arXiv每日学术速递 <https://www.arxivdaily.com/thread/61967>
117. Unsupervised Deep Embedded Clustering for High-Dimensional ... https://www.researchgate.net/publication/368774351_Unsupervised_Deep_Embedded_Clustering_for_High-Dimensional_Visual_Features_of_Fashion_Images
118. Deep Artificial Neural Networks Reveal a Distributed Cortical ... - PMC <https://pmc.ncbi.nlm.nih.gov/articles/PMC8176751/>
119. [PDF] A Network of Biologically Inspired Rectified Spectral Units (ReSUs ... <https://ojs.aaai.org/index.php/AAAI/article/view/37183/41145>
120. [PDF] Enhancing deep neural networks through complex-valued ... - HAL <https://hal.science/hal-05365191v1/file/2502.21077v2.pdf>
121. Whole-Neuron Synaptic Mapping Reveals Spatially Precise ... <https://www.cell.com/neuron/fulltext/S0896-6273%2820%2930138-0>
122. 'Backpropagation and the brain' realized in cortical error neuron ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC13089762/>
123. [PDF] Deep learning incorporating biologically-inspired neural dynamics <https://arxiv.org/pdf/1812.07040>
124. Biologically inspired heterogeneous learning for accurate, efficient ... <https://academic.oup.com/nsr/article/12/1/nwae301/7746334>
125. The architecture of the biologically inspired neural network. Each... https://www.researchgate.net/figure/The-architecture-of-the-biologically-inspired-neural-network-Each-layer-is-depicted-as-a_fig14_225030098
126. [2011.15031] A biologically plausible neural network for local ... - arXiv <https://arxiv.org/abs/2011.15031>
127. Energy-Aware Spike Budgeting for Continual Learning in ... - arXiv <https://arxiv.org/html/2602.12236v2>
128. Backpropagation-free spiking neural networks with the forward ... <https://www.nature.com/articles/s41598-026-41671-4>
129. [PDF] Layerwise Optimization by Gradient Decomposition for Continual ... https://openaccess.thecvf.com/content/CVPR2021/papers/Tang_Layerwise_Optimization_by_Gradient_Decomposition_for_Continual_Learning_CVPR_2021_paper.pdf
130. 人工智能2025_10_17 - arXiv每日学术速递 <http://www.arxivdaily.com/thread/72843>
131. Arxiv今日论文| 2026-02-12 - 闲记算法 http://lonepatient.top/2026/02/12/arxiv_papers_2026-02-12
132. An unsupervised STDP-based spiking neural network inspired by ... https://www.researchgate.net/publication/371801062_An_unsupervised_STDP-

based_spiking_neural_network_inspired_by_biologically_plausible_learning_rules_and_connections

133. [PDF] Enhancing deep neural networks through complex-valued ... - arXiv <https://arxiv.org/pdf/2502.21077>
134. [PDF] Associative memory and deep learning with Hebbian synaptic and ... <https://openreview.net/pdf?id=nXf2j6iFSc>
135. Connectome-constrained networks predict neural activity ... - Nature <https://www.nature.com/articles/s41586-024-07939-3>
136. Sparsey™: event recognition via deep hierarchical sparse ... - PMC <https://pmc.ncbi.nlm.nih.gov/articles/PMC4266026/>
137. Continual Learning Inspired by Brain Functionality: A ... <https://onlinelibrary.wiley.com/doi/10.1155/int/3145236>
138. Cortical feedforward, feedback and neuromodulatory information... https://www.researchgate.net/figure/Cortical-feedforward-feedback-and-neuromodulatory-information-streams-Diagram-of_fig1_323223873
139. 'Backpropagation and the brain' realized in cortical error neuron ... <https://journals.plos.org/ploscompbiol/article?id=10.1371/journal.pcbi.1014164>
140. Backpropagation Neural Tree - ScienceDirect.com <https://www.sciencedirect.com/science/article/pii/S0893608022000363>
141. (PDF) 'Backpropagation and the brain' realized in cortical error ... https://www.researchgate.net/publication/403930156_'Backpropagation_and_the_brain'_realized_in_cortical_error_neuron_microcircuits
142. [PDF] Exploring learning techniques for edge AI taking advantage of non ... https://theses.hal.science/tel-04866301/file/MARTEMUCCI_MICHELE_2024.pdf
143. (PDF) Bio-inspired neural networks implement different recurrent ... https://www.researchgate.net/publication/359112687_Bio-inspired_neural_networks_implement_different_recurrent_visual_processing_strategies_than_task-trained_ones_do
144. [PDF] A Robust Backpropagation-Free Framework for Images - OpenReview <https://openreview.net/pdf?id=leqr0vQzeN>
145. The neuroscience of transformers - arXiv <https://arxiv.org/html/2603.15339v1>
146. Feedforward and feedback frequency-dependent interactions in a ... <https://www.science.org/doi/10.1126/sciadv.1601335>
147. Toward an Integration of Deep Learning and Neuroscience - Frontiers <https://www.frontiersin.org/journals/computational-neuroscience/articles/10.3389/fncom.2016.00094/full>

148. Translaminar recurrence from layer 5 suppresses superficial cortical ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC9095870/>
149. Molecularly Defined Circuitry Reveals Input-Output Segregation in ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC4675718/>
150. Track: Poster Session TUE-AM - CVPR 2026 <https://cvpr.thecvf.com/virtual/2023/session/23307>
151. [PDF] Neuromorphic vision combining events and frames - HAL theses <https://theses.hal.science/tel-05549502v1/file/2025COAZ4044.pdf>
152. Hybrid neural networks for continual learning inspired by ... - Nature <https://www.nature.com/articles/s41467-025-56405-9>
153. Learning Interpretable Rules for Scalable Data Representation and ... <https://arxiv.org/html/2310.14336v3>
154. Sparse CapsNet with explicit regularizer - ScienceDirect.com <https://www.sciencedirect.com/science/article/abs/pii/S0031320321006622>
155. [PDF] Convolutional Channel-Wise Competitive Learning for the Forward ... <https://ojs.aaai.org/index.php/AAAI/article/view/29369/30584>
156. MobilePrune: Neural Network Compression via ℓ_0 Sparse Group ... <https://www.mdpi.com/1424-8220/22/11/4081>
157. Feedforward and feedback frequency-dependent interactions in a ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC5262462/>
158. [PDF] Can Local Learning Match Self-Supervised Backpropagation? - arXiv <https://arxiv.org/pdf/2601.21683>
159. [PDF] Approximating the Architecture of Visual Cortex in a Convolutional ... <https://openreview.net/pdf?id=NE6PDywWue>
160. Functional connectomics reveals general wiring rule in mouse visual ... <https://www.nature.com/articles/s41586-025-08840-3>
161. Convolutional Channel-wise Competitive Learning for the Forward ... <https://arxiv.org/html/2312.12668v1>
162. (PDF) Cortical networks with multiple interneuron types generate ... https://www.researchgate.net/publication/395403211_Cortical_networks_with_multiple_interneuron_types_generate_oscillatory_patterns_during_predictive_coding
163. 机器学习学术速递[10.22] - 腾讯云 <https://cloud.tencent.com/developer/article/1897647?policyId=1003>
164. Can Local Learning Match Self-Supervised Backpropagation? - arXiv <https://arxiv.org/html/2601.21683v1>

165. Learning-efficient spiking neural networks with multi-compartment ... <https://www.sciencedirect.com/science/article/pii/S2589004225007527>
166. Biologically Inspired Learning Model for Instructed Vision <https://openreview.net/forum?id=gJxEiRcnao-eId=CMkpCEMxzV>
167. iScience - Learning-efficient spiking neural networks with multi ... [https://www.cell.com/iscience/pdf/S2589-0042\(25\)00752-7.pdf](https://www.cell.com/iscience/pdf/S2589-0042(25)00752-7.pdf)
168. Arxiv今日论文 | 2026-03-12 - 闲记算法 http://lonepatient.top/2026/03/12/arxiv_papers_2026-03-12
169. [PDF] Scalable Learning in Structured Recurrent Spiking Neural Networks ... <https://arxiv.org/pdf/2605.00402>
170. Energy optimization induces predictive-coding properties in a multi ... <https://journals.plos.org/ploscompbiol/article?id=10.1371/journal.pcbi.1013112>
171. [PDF] d2l-en.pdf - Dive into Deep Learning <https://d2l.ai/d2l-en.pdf>
172. Inter-laminar microcircuits across neocortex: repair and augmentation <https://www.frontiersin.org/journals/systems-neuroscience/articles/10.3389/fnsys.2013.00080/full>
173. Arxiv今日论文 | 2026-03-04 - 闲记算法 http://lonepatient.top/2026/03/04/arxiv_papers_2026-03-04
174. [PDF] Hardware Design, Safety, and Security Dimensions of Spiking ... https://theses.hal.science/tel-05551511v1/file/146093_RAPTIS_2025_archivage.pdf
175. [PDF] d2l-en-mxnet.pdf - Dive into Deep Learning <https://d2l.ai/d2l-en-mxnet.pdf>
176. Dendritic solutions to the credit assignment problem | Request PDF https://www.researchgate.net/publication/327603179_Dendritic_solutions_to_the_credit_assignment_problem
177. (PDF) Classification of Alzheimer's Disease Based on Core-Large ... https://www.researchgate.net/publication/361258887_Classification_of_Alzheimer's_Disease_Based_on_Core-Large_Scale_Brain_Network_Using_Multilayer_Extreme_Learning_Machine
178. [PDF] Toward an Integration of Deep Learning and Neuroscience - Frontiers <https://www.frontiersin.org/journals/computational-neuroscience/articles/10.3389/fncom.2016.00094/pdf>
179. Cortical layer-specific differences in stimulus selectivity revealed ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC9048976/>
180. Methods for decoding cortical gradients of functional connectivity <https://pmc.ncbi.nlm.nih.gov/articles/PMC12224442/>
181. A data-based large-scale model for primary visual cortex enables ... https://www.researchgate.net/publication/365050456_A_data-based_large-

scale_model_for_primary_visual_cortex_enables_brain-
like_robust_and_versatile_visual_processing